

Format podatkov

CSV (`sword_results.csv`) iz JSON datotek, ki jih vrne SWORD2. Vrstice se združujejo po proteinih in proteini po particijah.

protein	PDB koda ter veriga, ki je bila uporabljena za SWORD2
aindex	ambiguity index proteina
partition	indeks particije. Optimalna ima 0, alternativne 1 ali več
quality	ocena particije
domain	indeks domene. Prva domena 1, druga domena 2, ...
AUL	AUL vrednost domene
start	prva aminokislina domene
end	zadnja aminokislina domene

Primer za 1a62_A:

protein	aindex	partition	quality	domain	AUL	start	end	
1a62_A	1	0	0	1	81	1	130	<--- opt.
1a62_A	1	1	1	1	70	1	47	<---- alt. 1
1a62_A	1	1	1	2	0	48	94	
1a62_A	1	1	1	3	46	95	130	
1a62_A	1	2	3	1	72	1	47	<---- alt. 2
1a62_A	1	2	3	2	8	48	130	
1a62_A	1	3	1	1	76	1	130	<--- alt. 3
1a62_A	1	3	1	2	0	48	94	

Filtriranje glede na sledeče pogoje

1. več kot ena domena v particiji
2. razmerje med katerokoli domeno v particiji naj ne bo večje od 1:2 (največ 1:3)
3. ambiguity index med 1 in 3
4. AUL vrednosti domen vsaj 75 (najmanj 50)

Prvotno je na voljo 1938 proteinov (glej Groups). Uporabil sem samo optimalne particije.

```
# A tibble: 2,741 × 8
# Groups:   protein [1,938]
  protein aindex partition quality domain  AUL start  end
  <chr>    <int>    <int>    <int>    <int> <int> <int> <int>
1 1a62_A      1        0        0        1    81     1   130
2 1ab1_A      0        0        8        1    79     1    46
3 1af7_A      3        0        3        1    56     1    80
4 1af7_A      3        0        3        2    86    81   274
5 1ah7_A      2        0        0        1    90     1   245
6 1ail_A      1        0        0        1    86     1    73
7 1aol_A      1        0        0        1    90     1   228
8 1b0n_A      2        0        0        1    80     1   111
9 1b2s_E      1        0        0        1    59     1    90
10 1b2s_F     1        0        0        1    70     1    90
# i 2,731 more rows
# i Use `print(n = ...)` to see more rows
```

Število Domen

Ostane jih 560 z dvema ali več domenami.

```
# A tibble: 1,363 × 8
# Groups:   protein [560]
  protein aindex partition quality domain  AUL start  end
  <chr>    <int>    <int>    <int>  <int> <int> <int>
1 1af7_A      3        0        3      1    56     1    80
2 1af7_A      3        0        3      2    86    81   274
3 1c96_A      3        0        4      1    93     1   529
4 1c96_A      3        0        4      2    58   530   753
5 1d3y_A      3        0        4      1     3     1    74
6 1d3y_A      3        0        4      2    85    75   301
7 1d3y_B      3        0        4      1     0     1    74
8 1d3y_B      3        0        4      2    86    75   301
9 1dd3_A      1        0        4      1    83     1    49
10 1dd3_A      1        0        4      2    92    50   128
# i 1,353 more rows
# i Use `print(n = ...)` to see more rows
```

Razmerja med velikostmi domen

A-index

AUL vrednosti